

杨子逸

手机：19924680829

邮箱：yangzy39@mail2.sysu.edu.cn

个人主页：<https://yangzy39.github.io>

实习意向：大模型算法 NLP 算法



教育背景

中山大学 计算机学院

2023.09 - 至今

计算机技术专业，硕士研究生，导师：权小军教授

- 研究方向：模型融合 偏好优化

中山大学 计算机学院

2019.09 - 2023.06

计算机科学与技术专业，本科

- 相关课程：自然语言处理 人工智能 机器学习与数据挖掘

科研经历

首次提出了**基于偏好优化的隐式模型融合**研究问题，旨在从偏好优化的角度出发，将多个功能强大源模型的能力隐式地迁移并整合到一个规模更小更加高效的目标模型中

Weighted-Reward Preference Optimization for Implicit Model Fusion

2024.06 - 2024.10

[\[Paper\]](#) / [\[Github\]](#) / [\[HF\]](#)

• 研究内容

- 针对现有模型融合中的词表对齐与分布矩阵对齐困难、效率低下等问题，提出加权奖励偏好优化方法（WRPO），其核心思想是让目标模型隐式地从源模型和自身回复之间的差异中进行学习
- 为解决目标模型与源模型间的分布偏差，提升融合稳定性与效率，提出内部奖励加权方案，并结合渐进式调整策略，使目标模型逐步学习来自源模型的偏好样本

• 研究成果

- WRPO 显著优于相同参数规模的模型融合方法，媲美 106 倍参数规模的模型集成方法；在 AlpacaEval-2 评测集上超越所有参与融合的模型，相较于传统偏好学习 DPO 方法提升了 7.7 分
- 相关论文已被 ICLR2025 录用，**第一作者**

FuseChat-3.0: Preference Optimization Meets Heterogeneous Model Fusion

2024.10 - 2024.12

[\[Paper\]](#) / [\[Github\]](#) / [\[HF\]](#) / [\[魔搭社区\]](#)

• 研究内容

- FuseChat-3.0 是对 WRPO 核心思想的实践延伸，进一步改进并拓展了融合数据的领域和规模
- 针对数学和代码领域，引入基于规则验证的数据合成方案，在 DPO 损失中增加长度约束项

• 研究成果

- 融合模型 FuseChat-3.0-8B 在 14 个基准测试集上的平均性能相比目标模型 Llama-3.1-8B-Instruct 提升 **16.8%**，成为 AlpacaEval-2 和 Arena-Hard 榜单中**最强 8B 模型**
- 成果被阿里云魔搭社区报导，并获国家超级计算广州中心 2024 “天河之星”优秀应用入围奖
- 相关论文已被 SCI-FM @ ICLR2025 录用，**第一作者**

FuseRL: Dense Preference Optimization for Heterogeneous Model Fusion

2024.10 - 2025.01

• 研究内容

- FuseRL 提出一个新的异构模型融合框架，核心思想是最大化源模型回复的利用率
- 对每条输入引入多个来自源模型的回复或偏好对，并结合奖励分数进行加权 SFT 或加权偏好优化

• 研究成果

- FuseRL 结合偏好优化方法 DPO/SimPO 在 AlpacaEval-2 测试集上分别提升 3.0/5.9 分
- 相关论文投稿 ICML2025，**第三作者**

项目经历

FuseChat: 对话大模型融合

2023.10 - 2024.05

[\[Paper\]](#) / [\[Github\]](#) / [\[HF\]](#) / [\[mergekit\]](#)

- **负责部分:** 主要负责模型合并算法的设计与优化、模型训练以及性能评测
- **项目内容:** 通过词表和分布矩阵对齐实现异构模型蒸馏, 提出多教师蒸馏加模型合并的两阶段融合框架, 将多个结构和规模各异对话大模型知识整合到一个目标模型中
- **项目成果:**
 - 融合得到的 FuseChat-7B 是当时多轮对话评测集 MT-Bench 上**最佳 7B 模型**
 - 该成果入选 HuggingFace 每日论文精选, 并受邀在**机器之心**平台进行实测直播
 - 提出的模型合并算法 SCE 被 Github 超过 **5300 星标**的知名模型合并仓库 mergekit 收录

FuseO1: 推理大模型融合

2025.01 - 至今

[\[Blog\]](#) / [\[Github\]](#) / [\[HF\]](#)

- **负责部分:** 主要负责数据清洗、数据分析以及评测框架搭建
- **项目内容:** 将 FuseChat 中的 SCE 模型合并方法应用于推理大模型融合, 探索 DeepSeek-R1 的完整流程复现, 研究推理模型长思维链的可解释性
- **项目成果:**
 - 通过 SCE 合并算法将 DeepSeek-R1-32B, QwQ-32B, Sky-T1-32B 融合, 在多个推理评测集上**超越所有参与融合的模型**, 在 AIME24 评测集上相较 DeepSeek-R1-32B 提升 4.8 分
 - 融合模型在 HuggingFace 首页亮相, 下载量突破 **10 万次**